


⚡ PFM · MUCSI · FASE 1 COMPLETADA

Predicción del consumo eléctrico en hogares con **Machine Learning**



Una base de datos limpia, analizada en profundidad y con features de calidad — lista para el modelado.

 MOTIVACIÓN

El consumo doméstico es la pieza más volátil de la red.

Anticiparlo con precisión permite reducir picos, integrar renovables y bajar la factura. El reto: las series son ruidosas, no estacionarias y muy específicas de cada hogar.

~30%

del consumo eléctrico total
proviene del sector residencial

+30%

de diferencia invierno vs verano
observada en House1

7 s

resolución temporal real del dataset
— una lectura cada 7 segundos

 REFIT ELECTRICAL LOAD MEASUREMENTS

3 hogares reales del Reino Unido, ~2 años de mediciones.

HOGAR	REGISTROS RAW	PERÍODO	CONSUMO MEDIO	MÁX. DETECTADO
House1	6.960.008	Oct 2013 — Jul 2015	481 W	29.159 W
House2	5.733.526	Sep 2013 — May 2015	465 W	24.595 W
House3	6.994.594	Sep 2013 — Jun 2015	679 W	 65.836 W

 **Anomalía detectada en House3:** pico de 65.836 W — físicamente imposible, el suministro doméstico UK máximo es 23.000 W (100A × 230V).

19,7M

filas brutas combinadas

9 + 1

electrodomésticos + Aggregate

Zenodo

datos reales UK · 2013–2015

 LO QUE SE HA HECHO

4 notebooks, una base de datos lista para entrenar modelos.



NOTEBOOK 01 • 11 ABR

Inspección inicial

Carga sin modificar nada. Detecta intervalo real (7s $\neq$ 8s), 0 NaN nativos, **5,84% Issues=1 en House3** y el outlier de 65.836 W.



NOTEBOOK 02 • 11 ABR

EDA visual para tutora

Patrones temporales: doble pico diario (07-09h, 18-21h), desplazamiento +1h en fines de semana, estacionalidad anual **+30% invierno**.



NOTEBOOK 03 • 17 ABR

Limpieza de datos

Pipeline 4 pasos. **~2,7M filas limpias** a 1 minuto. House2 marcado solo para validación cruzada (23,69% NaN final).




NOTEBOOK 04 • 26 ABR

EDA estadístico + Features

Tests ADF/KPSS, descomposición estacional, ACF/PACF. **36 features** en 5 grupos. 7 figuras + 5 CSVs producidos.

🔑 NOTEBOOK 03 – FLUJO COMPLETO

De 19,7M filas brutas a ~2,7M filas listas para entrenar.



01FILTRAR

Eliminar Issues=1

Lecturas marcadas defectuosas

-495.254

House3: -5,84%

02OUTLIERS

Cap a 15.000 W

Límite físico UK conservador

65.836 W

→ 12.628 W

03REMUESTREAR

7s → 1 minuto

Media por minuto · estándar NILM

~7x

reducción volumen

04IMPUTAR

Gaps ≤ 30 min

Interpolación lineal

23,69%

NaN final House2 ⚠️

Decisión clave • House2 con 23,69% NaN → solo validación cruzada, NO entrenamiento

 LO QUE DICEN LOS DATOS

4 hallazgos que condicionan todo el modelado posterior.

→ HALLAZGO 01

Distribución muy asimétrica

asimetría > 3 · leptocúrtica. La serie **NO es normal** — hay que evitar métricas y modelos que asuman gaussianidad.

→ HALLAZGO 02

Ciclo diario muy marcado

Doble pico diario: **07–09h** y **18–21h**. Fin de semana desplaza el pico +1h y mantiene consumo más sostenido.

→ HALLAZGO 03

Autocorrelación clara en ACF

Picos en **lag 60** (1h) y **lag 1.440** (1 día). Justifica directamente las features de lag y ventana deslizando.

→ ALERTA • HOUSE2

Demasiados huecos largos

23,69% NaN final tras imputación — concentración temporal de gaps. Se reserva **solo para validación cruzada**.

 NOTEBOOK 04 — 5 GRUPOS DE FEATURES

36 features construidas a partir del ciclo, los lags y la ventana.



GRUPO 01

Temporales

9

hora
dia_semana
mes
trimestre
estacion



GRUPO 02

Cíclicas

8

hora_sin/cos
mes_sin/cos
dia_sin/cos



GRUPO 03

Binarias

3

es_finde
es_festivo_uk
estacion



GRUPO 04

Lags

8

lag_1
lag_60 (1h)
lag_1440 (día)
lag_10080 (sem)



GRUPO 05

Ventana

8

media_movil_60
std_movil_60
max_movil_60

TOTAL CONSTRUIDO

36 features • 5 grupos

justificadas por ACF, ciclo diario y estética NILM


 5 ELECCIONES QUE DEFINEN EL PROYECTO

Cada decisión, justificada.

01	Umbral outlier 15.000 W	Límite físico conservador del suministro doméstico UK ($100A \times 230V = 23.000\text{ W}$).
02	Remuestreo a 1 minuto	Estándar en literatura NILM. Elimina la irregularidad del intervalo de 7 s y reduce $\sim 7\times$.
03	Imputar solo gaps $\leq 30\text{ min}$	No fabricar datos en ausencias largas — preserva la integridad estadística.
04	House2 $\rightarrow$ solo validación	23,69% NaN concentrados temporalmente: comprometería el entrenamiento.
05	Codificación cíclica sin/cos · semilla 42	Evita discontinuidad hora 23 $\rightarrow$ 0. Semilla fija = reproducibilidad total del proyecto.

 FASE 2 — MODELADO Y COMPARATIVA

Del baseline al deep learning, en orden creciente de complejidad.



MÉTRICAS DE EVALUACIÓN

- RMSE
- MAE
- MAPE
- R²

VALIDACIÓN

Walk-forward temporal estricta
(nunca aleatoria — preserva la causalidad)

Una fase completada, dos por delante.

✓ FASE 1 · COMPLETADA EDA + Features — Inspección inicial 3 hogares — EDA visual para tutora — Pipeline de limpieza (4 pasos) — EDA estadístico + 36 features	→ FASE 2 · SIGUIENTE Modelado — Baseline + ARIMA — XGBoost · LightGBM · RF — LSTM (+ Transformer opcional) — Walk-forward · RMSE/MAE/MAPE/R²	□ FASE 3 · PENDIENTE Dashboard + Memoria — Dashboard interactivo — Memoria LaTeX — Defensa
--	---	--

Hasta aquí: una base de datos **limpia**, analizada en **profundidad** y con **features de calidad** — lista para el modelado.